PROJET D1 · 5A · SOUTENANCE DU 28 OCTOBRE 2026

Un agent vocal en temps réel

Une IA à qui l’on parle vraiment : elle répond en quelques secondes, et on peut lui couper la parole.

Pierre Ingrachen--Boutantin

INTRODUCTION

Le projet en une minute

Vous posez une question à voix haute. Quelques secondes plus tard, une voix vous répond. Et si vous l'interrompez, elle s'arrête.

Le sujet

Un agent vocal en temps réel, où la rapidité de réponse compte.

Le défi

Enchaîner trois modèles d'IA sans que la conversation sonne artificielle.

Notre démarche

Construire, mesurer chaque étape, puis dire honnêtement ce que ça vaut.

LE PROJET

Ce qu’on a construit

Une vraie conversation

L’agent commence à répondre avant d’avoir fini sa réponse, comme quelqu’un qui parle.

Qu’on peut couper

On l’interrompt en pleine phrase : il se tait et nous écoute.

Qui ne lâche pas

Si la voix tombe en panne, on continue au clavier avec la même chaîne.

Comment on juge le résultat

Le temps de réponse à chaque étape · les interruptions bien gérées · les erreurs de transcription dans le bruit

ARCHITECTURE

Comment ça marche



Orchestrateur

Il fait passer la voix d'une étape à l'autre, se tait dès qu'on lui coupe la parole, et chronomètre chaque étape.

CHOIX TECHNIQUES

Nos choix, et pourquoi

Brique	Choix	Pourquoi
VAD	Silero, en local	Léger : moins de 1 ms par trame
STT	Whisper large-v3-turbo	Serveur de l'école, ≈ 0,45 s par énoncé
LLM	DeepSeek V4.1 Flash	Premier mot en ≈ 0,3 s, recherche web
TTS	MiniMax speech-2.8-turbo	Voix française validée à l'écoute

Pourquoi une cascade ? Chaque étape se mesure et se remplace. Un modèle voix-à-voix serait une boîte noire, impossible à chronométrer étape par étape.

LATENCE

Gagner (et masquer) du temps

Streaming par phrases

La voix démarre dès la première phrase du LLM, sans attendre la fin.

STT spéculatif

La transcription part après 200 ms de silence, avant la fin de tour : ≈ 260 ms gagnés.

Accroche d’ouverture

Une courte phrase pré-enregistrée (« Hmm, voyons. ») : premier son en ≈ 0,5 s.

Préchauffage

Le premier appel au Whisper de l’école a pris 35 s à froid : on le chauffe au démarrage.

BARGE-IN

On peut lui couper la parole

1

Il entend

Le VAD reste actif quand l'agent parle ; il faut ≈ 300 ms de parole franche.

2

Il se tait

Le LLM et le TTS sont annulés, la lecture s'arrête côté navigateur.

3

Il oublie

La mémoire ne garde que ce que l'utilisateur a vraiment entendu.

4

Il écoute

Le début de la phrase est conservé, rien n'est perdu.

POURQUOI C’EST UTILE

Demander plutôt que chercher

Du temps gagné

- On parle bien plus vite qu’on ne tape : une phrase suffit.
- La réponse s’écoute en faisant autre chose, sans lire un écran.
- L’agent cherche sur internet à votre place et vous dit ce qu’il fait.

Plus accessible

- Aucun clavier ni écran nécessaire : mains occupées, vue ou dextérité limitées.
- On le coupe comme on couperait quelqu’un : pas besoin d’attendre la fin.
- Si la voix lâche, le clavier prend le relais : personne n’est bloqué.

Parler à une machine devrait être aussi naturel que parler à quelqu’un.

MESURES

Ce que ça donne

2,06 s

fin de parole → réponse, médiane (p95 : 2,45 s)

0,52 s

premier son avec l’accroche d’ouverture

32/32

interruptions détectées à temps, médiane 372 ms (simulation hors ligne)

≈ 0 %

erreur de mots jusqu’à 5 dB de bruit

DÉMONSTRATION

En direct, dans le navigateur

1. Une question qui demande une recherche sur internet

2. Couper la parole à l’agent en pleine phrase

3. Panne de la voix : bascule en mode texte

ROBUSTESSE

Et si ça plante ?

Brique	Principal	Si ça échoue
STT	Whisper de l’école	Qwen3 ASR, puis mode texte après 2 échecs
LLM	DeepSeek V4.1 Flash	Qwen3.8 27B avant le premier mot
TTS	MiniMax	Qwen TTS, puis réponse écrite

Et aussi : un bruit ou un silence mal compris ne déclenche pas de réponse parasite, et chaque appel a un délai maximum.

LIMITES ET SUITES

Ce qu’on ne sait pas encore

Limites

- Voix et bruits de synthèse, petits échantillons : le p95 reste indicatif.
- Français uniquement pour l’instant.
- Foule dense : la fin de parole n’est plus détectée dès 10 dB.
- Fin de tour à 450 ms : environ un tiers des phrases coupées dans notre lot.

Pistes

- **Plusieurs langues :** choisir sa langue, et l’agent répond dans la même.
- **Plus rapide :** lancer la recherche web pendant que l’on parle encore.
- **Fin de tour adaptative :** attendre davantage si la phrase semble inachevée.
- **Mémoire plus longue :** retenir la conversation d’une session à l’autre.

CONCLUSION

Ce qu’on a accompli

- Une conversation vocale complète, du micro à la voix, dans le navigateur
- Une interruption en pleine phrase : l’agent se tait et écoute
- Une recherche sur internet, annoncée à voix haute pendant l’attente
- Un secours à chaque étape, jusqu’au mode texte
- Une campagne de mesures : vitesse, interruptions, bruit
- Des tests automatiques et un journal de 28 décisions

Merci. Des questions ?